

Lineamientos para la evaluación del curso Inteligencia Artificial Híbridos Supervisados

O. L. Quintero

28 de febrero de 2023

Resumen

Este documento contiene los lineamientos para la presentación de la actividad evaluativa.

1. Introducción

El objetivo del curso es proveer elementos teóricos y conceptuales que le permitan a los estudiantes de Inteligencia Artificial de Ingeniería Matemática, enfrentar el problema de construir un modelo compacto (learning machine) que permita representar fenómenos del mundo real.

Consecuentemente, los principios de teoría de aprendizaje fueron adelantados en la clase. Se debe cuestionar y NO desviar la tarea de aprendizaje automático, es decir no "presuponer" la naturaleza del mismo. Debe explorarse la construcción de diversos modelos mediante la aplicación de los conceptos.

El curso pretende adelantar la correcta aplicación de conceptos que permiten construir el modelo, evaluarlo y juzgar con perspectiva científica su desempeño.

Cuando me refiero a perspectiva científica quiero decir que el valor agregado diferenciador del ingeniero matemático es su dominio de las matemáticas subyacentes a las herramientas que domina, de esta forma los conceptos matemáticos y cotas de aprendizaje de clase y la formalización es la que permitirá que en la vida real den respuesta a problemas de ingeniería y que no se den por vencidos a la primera vez que un modelo no funcione.

Siempre que aborden un problema de inteligencia artificial, deben asegurarse que los datos cumplen con los requisitos específicos de tratamiento, y que básicamente el problema no pueda ser resuelto por otras vías tradicionales.

Si el problema podría ser resuelto como un modelo de identificación de sistemas o un sistema lineal, el uso de inteligencia artificial básicamente demeritaría la aplicación y adicionaría complejidad innecesaria.

Olvídese del R^2 y del accuracy, eso en el mundo real no tiene significado al lado de los requisitos de especificidad y sensibilidad del problema. El uso del Receiver Operator Curve que relaciona los anteriores para cada uno de los modelos que va a comparar, es una de las formas más útiles y comprensibles de juzgar el modelo, siempre sobre los datos de prueba.

Su ideal de que le de perfecto, puede ser abandonado siempre y cuando se cumplan los objetivos de aprendizaje y su modelo no este sobreentrenado. El peor pecado y desprestigio de un modelador es que el modelo sobreentrenado con pocos datos, no generalice la muestra. Por encima de todo, un correcto procedimiento y la garantía de aprendizaje, así sea cumplida a un porcentaje bajo.

Luego de la cantaleta obvia de este ultimo ejercicio, procedo a indicar cuales son los procedimientos que nos permitirán lograr los resultados de aprendizaje del curso:

Esta actividad evaluativa consiste en entrenar varios modelos de aprendizaje híbrido supervisado

1. Autoencoders
2. Redes convolucionales
3. Generative adversarial networks

Los conceptos generales se pueden revisar directamente del libro "Machine Intelligence for decision making" (en borrador para uso de los estudiantes de este curso y bajo edicion por Springer), y de las diversas fuentes citadas en el libro con artículos científicos y otros libros mas especializados en cada tema.

Para comenzar a realizar su proceso de aprendizaje (me refiero a practicar en datos juguete antes de abordar el problema real), el estudiante puede usar conjuntos de datos sintéticos que haya como ejemplo en cualquier programa o suite.

2. Autoencoders

Vamos a trabajar el problema de simplificacion de informacion, usando autoencoders para extraer informacion de los datos comprimiendo el espacio mediante codificacion y extrayendo características mediante ampliacion de la dimensionalidad del problema.

1. Seleccionar un problema que sea de multiples entradas y multiples salidas
2. Dividir el conjunto de muestra en: entrenamiento, validación y prueba.
Usando una distribucion uniforme sobre el conjunto S de datos que tenemos, rogando al señor Dios que el dataset S (o sea la tabla que van a usar) sea representativo de la realidad.
3. Autocodificar en bajas dimensiones el problema usando su propio codigo de MLP del examen presentado. Esto significa que usamos en la capa oculta menos neuronas que la capa de entrada.
4. Autocodificar en altas dimensiones el problema usando su propio codigo de MLP del examen presentado. Esto significa que usamos en la capa oculta menos neuronas que la capa de entrada.

5. Entrenar un MLP de cualquier paquete con la informacion del codigo de reduccion del punto 3 y el de ampliacion del punto 4.

3. Redes Neuronales Convolucionales

Este tipo de arquitecturas se usa para realizar clasificacion, localizacion o segmentacion de imagenes. Es decir, patrones en altas dimensiones.

Las imagenes son normalmente puntos en el espacio con características de frecuencia espacial muy diferentes a las de los problemas clasicos que se abordan en aprendizaje de maquina.

Reconocer ya sea clases, localizar o segmentar objetos requiere que se logren capturar las características espaciales diferenciadores en los kernels de convolucion y luego estas características simplificadas se lleven a un espacio donde un MLP pueda separarlas.

El objetivo **sera entrenar una red convolucional tipo LeNet 5** muy simple para reconocimiento de digitos. Esta red es la conocida por su base de datos MNIST.

La arquitectura Lenet5 esta aqui:

<https://www.kaggle.com/niranjajagannath/lenet-5-architecture-for-mnist-using-tensorflow>

Y por aqui les dejo el proyecto en Collab:

https://colab.research.google.com/github/d2l-ai/d2l-en-colab/blob/master/chapter_convolutional_neural_networks/lenet.ipynb

La idea es repetir el entrenamiento, PERO CON LA BASE DE DATOS ORIGINAL!!

"The MNIST Handwritten Digit Classification Challenge is the classic entry point. Image data is generally harder to work with than "flat" relational data. The MNIST data is beginner-friendly and is small enough to fit on one computer. Handwriting recognition will challenge you, but it doesn't need high computational power."

En esta pagina web encontraran no solo la base de datos sino multiples maquinas de aprendizaje trabajadas para lograr hacer la diferenciacion de las 10 clases. <http://yann.lecun.com/exdb/mnist/>

Note que se presentan las maquinas de aprendizaje tradicionales y luego las redes convolucionales.

Si usted puede resolver este problema, que fue el seminal en 1998 para redes convolucionales, entonces puede moverse al siguiente punto. Si no es capaz, por favor continue intentand y vengamos a asesoria.

Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. "Gradient-based learning applied to document recognition." Proceedings of the IEEE, 86(11):2278-2324, November 1998

4. A generative adversarial network (GAN)

Ahora movamonos a algo mas interesante. Si ya logro entrenar una LeNet desde la base de datos MNIST hacia los codigos de repositorios, seguro ha tenido que lidiar con imagenes. A estas alturas vamos a explorar los tipos de redes convolucionales del tipo Generador y la arquitectura GANS.

A generative adversarial network (GAN) is a class of machine learning frameworks invented by Ian Goodfellow and his colleagues in 2014. See Goodfellow, Ian; Pouget-Abadie, Jean; Mirza, Mehdi; Xu, Bing; Warde-Farley, David; Ozair, Sherjil; Courville, Aaron; Bengio, Yoshua (2014). Generative Adversarial Networks (PDF). Proceedings of the International Conference on Neural Information Processing Systems (NIPS 2014). pp. 2672–2680.

Two neural networks contest with each other in a game (in the sense of game theory, often but not always in the form of a zero-sum game). Given a training set, this technique learns to generate new data with the same statistics as the training set.

For example, a GAN trained on photographs can generate new photographs that look at least superficially authentic to human observers, having many realistic characteristics.

Though originally proposed as a form of generative model for unsupervised learning, GANs have also proven useful for semi-supervised learning, fully supervised learning, and reinforcement learning.

La actividad es hacer un primer acercamiento en collab para hacer una arquitectura con Generador y Discriminador para MNIST dado que ya conocen la base de datos y la arquitectura convolucional simple. Un ejemplo de codigo es esta:

<https://colab.research.google.com/github/timsainb/tensorflow2-generative-models/blob/master/2.0-GAN-fashion-mnist.ipynb>

<https://colab.research.google.com/github/smartgeometry-ucl/dl4g/blob/master/gan.ipynb>

https://colab.research.google.com/github/lexfridman/mit-deep-learning/blob/master/tutorial_gans/tutorial_gans.ipynb

La tarea es entrenar un GANS para MNIST y reportar su entrenamiento.

Aqui en Matlab nosotros tenemos la licencia de campus con todos los toolboxes <https://www.mathworks.com/help/deeplearning/ug/train-generative-adversarial-network.html> <https://www.mathworks.com/help/deeplearning/ug/train-generative-adversarial-network.html#TrainGenerativeAdversarialNetworkGANExample-7>

La siguiente actividad es hacer una transferencia de estilo StyleGANS que encontraran con el codigo disponible aqui:

<https://github.com/NVlabs/stylegan2>

The style-based GAN architecture (StyleGAN) yields state-of-the-art results in data-driven unconditional generative image modeling. We expose and analyze several of its characteristic artifacts, and propose changes in both model architecture and training methods to address them. In particular, we redesign the generator normalization, revisit progressive growing, and regularize the generator to encourage good conditioning in the mapping from latent codes to images.

In addition to improving image quality, this path length regularizer yields the additional benefit that the generator becomes significantly easier to invert. This makes it possible to reliably attribute a generated image to a particular network. We furthermore visualize how well the generator utilizes its output resolution, and identify a capacity problem, motivating us to train larger models for additional quality improvements. Overall, our improved model redefines the state of the art in unconditional image modeling, both in terms of existing distribution quality metrics as well as perceived image quality

Es decir, que la entrenen y la actividad de campo es la siguiente:

Salir a dar un paseo de 10 minutos con su celular y grabar su camino. Si encuentra personas con mascarillas o cosas, puede hacerles una toma mas cercana. Esta grabacion la vamos a convertir en una serie de imagenes que vamos a utilizar para probar nuestra arquitectura GANs de Transferencia de Estilo. Cuando la red de transferencia nos entregue la imagen de salida, vamos a recrear el video con las salidas de nuevo y lo vamos a mostrar.

<https://ezgif.com/video-to-jpg>

<https://www.youtube.com/watch?v=u8qPvzk0AfY>.

4.1. Entregables

Se debe entregar:

- Documento informe
- Codigos elaborados

Por favor asistir a asesoría con el profesor del curso en la plataforma teams y solicitar su cita con anticipación al correo oquinte1@eafit.edu.co.